

# Modelos para la Detección de Distracciones al Volante

**Carlos Seoane, Miguel Valle, Santiago Nuñez**

Computer Vision y YOLOv8 para monitorización en tiempo real del comportamiento del conductor





# El Problema: Distracción al Volante

## Impacto en siniestralidad

La distracción al volante está implicada en aproximadamente el 14% de los accidentes fatales en carretera.


## Objetivo del proyecto

Desarrollar un sistema de IA capaz de monitorizar el habitáculo en tiempo real y clasificar conductas de riesgo: uso del móvil, comer, beber o apartar las manos.

## Enfoque técnico

Computer Vision con detección de objetos que no solo identifica la distracción, sino que la **localiza espacialmente** mediante bounding boxes.

# Selección Tecnológica: YOLO vs. Transformers



## RT-DETR (Transformers)

Mecanismo de **Atención Global**:  
analiza toda la imagen simultáneamente  
para entender contexto complejo.  
Requiere alta capacidad de cómputo.

## YOLOv8 Nano Seleccionado

Arquitectura CNN ligera. Permite  
inferencia en tiempo real en  
dispositivos de bajos recursos (Edge  
Computing), sin depender de  
conectividad a la nube.



# Metodología: Estudio de Ablación

Para encontrar la configuración de entrenamiento óptima, se llevó a cabo un **Estudio de Ablación**: metodología empírica que establece un Modelo Base y crea variaciones alterando un único hiperparámetro cada vez.

1

## Modelo Base

YOLOv8 Nano estándar

2

## Variaciones

Un hiperparámetro alterado por experimento

3

## Comparativa

6 experimentos, máx. 30 épocas



# Los 6 Experimentos del Estudio

1

## Base

YOLOv8n, 640px, SGD, Mosaico activo (mezcla 4 fotos en 1).

2

## V1 — Sin Mosaico

*mosaic=0.0*. Hipótesis: procesar el habitáculo sin cortes mejora la comprensión geométrica.

3

## V2 — AdamW

Optimizador inteligente. Hipótesis: convergencia más rápida y estable.

4

## V3 — Rotación 15°

*degrees=15.0*. Hipótesis: robustez ante baches o desajustes de cámara.

5

## V4 — Alta Resolución


*imgsz=800*. Hipótesis: mejor detección de objetos pequeños (cigarrillos, smartphones).

6

## V5 — Dropout 0.15

*dropout=0.15*. Hipótesis: "freno de memorización" para evitar overfitting.



# Resultados Analíticos del Laboratorio



## Conclusiones clave

- **Modelo Base** lidera con mAP50-95: **98.70%** (época 25).
- **Colapso de AdamW:** YOLOv8 está calibrado para SGD. Inyectar AdamW sin recalibrar la tasa de aprendizaje provocó colapso de gradientes (mAP: 18.34%).
- **Dominio geométrico (V1):** Sin mosaico, el modelo obtuvo el **Box Loss más bajo** (0.0728), demostrando que conservar la estructura original del coche favorece la localización espacial.

# Métricas



# El Desafío del Overfitting Estadístico

## La sospecha

Un mAP50-95 del **98.70%** levantó sospechas de sobreajuste extremo.

## Diagnóstico: Fuga de Datos

Los fotogramas extraídos de secuencias de vídeo, separados por escasos milisegundos, presentaban al mismo conductor y habitáculo tanto en entrenamiento como en evaluación.

## Consecuencia

Las métricas del examen final estaban artificialmente infladas. El modelo no demostraba generalización, sino reconocimiento de condiciones exactas de iluminación, fondos y sujetos del dataset.



# Validación Empírica y Domain Shift

Se construyó un prototipo funcional con **Streamlit** para probar el modelo en escenarios reales ajenos al entrenamiento (Out-of-Distribution).

## Escenario A — Imágenes similares

Con focal, perspectiva e iluminación afines, el modelo **mantuvo precisión notable**: aisló correctamente móvil, brazos y postura. Demuestra sólida generalización conceptual.

## Escenario B — Webcam en vivo

Con ángulos frontales, distinta temperatura de color y posturas no estandarizadas, el rendimiento **cayó drásticamente**.

---

## Diagnóstico: Domain Shift

La red neuronal generó fuerte dependencia a la "**firma óptica**" de la cámara del dataset original. El modelo sabe qué buscar, pero solo lo encuentra si la imagen se ajusta a las reglas memorizadas.

# App Streamlit

- Carga de imágenes para probar el modelo con distintos escenarios de entrada.
- Procesamiento en tiempo real para evaluar el comportamiento del conductor de forma inmediata.
- Visualización de detecciones mediante bounding boxes sobre las regiones de interés.



# Conclusiones Clave y Próximos Pasos

## 1 Validación Empírica Esencial

Las métricas de laboratorio pueden ser engañosas. Es vital validar el rendimiento del modelo en escenarios reales y no vistos para comprender su verdadera capacidad de generalización.

## 2 Mitigar el Domain Shift

El rendimiento del modelo cayó drásticamente en entornos Out-of-Distribution. Futuros trabajos deben centrarse en técnicas como la adaptación de dominio o el aumento de datos inteligente para robustecer la detección.

## 3 Optimización Continua

Aunque YOLOv8 Nano demostró ser un modelo ligero y eficaz, la exploración de diferentes configuraciones de entrenamiento y arquitecturas sigue siendo fundamental para maximizar su eficiencia y precisión en condiciones variadas.

## 4 Hacia la Implementación Real

El prototipo de Streamlit confirma la viabilidad del concepto. Los próximos pasos incluyen la integración con hardware embebido y la realización de pruebas piloto en vehículos para recopilar datos reales y cerrar el ciclo de mejora.

# Gracias por su atención

Carlos Seoane, Miguel Valle, Santiago Nuñez