

Modelos para la Detección de Distracciones al Volante

Carlos Seoane, Miguel Valle, Santiago Nuñez

Computer Vision y YOLOv8 para monitorización en tiempo real del comportamiento del conductor





El Problema: Distracción al Volante

Impacto en siniestralidad

La distracción al volante está implicada en aproximadamente el 14% de los accidentes fatales en carretera.


Objetivo del proyecto

Desarrollar un sistema de IA capaz de monitorizar el habitáculo en tiempo real y clasificar conductas de riesgo: uso del móvil, comer, beber o apartar las manos.

Enfoque técnico

Computer Vision con detección de objetos que no solo identifica la distracción, sino que la **localiza espacialmente** mediante bounding boxes.

Selección Tecnológica: YOLO vs. Transformers



RT-DETR (Transformers)

Mecanismo de **Atención Global**:
analiza toda la imagen simultáneamente
para entender contexto complejo.
Requiere alta capacidad de cómputo.

YOLOv8 Nano Seleccionado

Arquitectura CNN ligera. Permite
inferencia en tiempo real en
dispositivos de bajos recursos (Edge
Computing), sin depender de
conectividad a la nube.

Metodología: Estudio de Ablación

Para encontrar la configuración de entrenamiento óptima, se llevó a cabo un **Estudio de Ablación**: metodología empírica que establece un Modelo Base y crea variaciones alterando un único hiperparámetro cada vez.

1

Modelo Base

YOLOv8 Nano estándar

2

Variaciones

Un hiperparámetro alterado por experimento

3

Comparativa

6 experimentos, máx. 30 épocas



Los 6 Experimentos del Estudio

1

Base

YOLOv8n, 640px, SGD, Mosaico activo (mezcla 4 fotos en 1).

2

V1 — Sin Mosaico

mosaic=0.0. Hipótesis: procesar el habitáculo sin cortes mejora la comprensión geométrica.

3

V2 — AdamW

Optimizador inteligente. Hipótesis: convergencia más rápida y estable.

4

V3 — Rotación 15°

degrees=15.0. Hipótesis: robustez ante baches o desajustes de cámara.

5

V4 — Alta Resolución


imgsz=800. Hipótesis: mejor detección de objetos pequeños (cigarrillos, smartphones).

6

V5 — Dropout 0.15

dropout=0.15. Hipótesis: "freno de memorización" para evitar overfitting.



Resultados Analíticos del Laboratorio



Conclusiones clave

- **Modelo Base** lidera con mAP50-95: **98.70%** (época 25).
- **Colapso de AdamW:** YOLOv8 está calibrado para SGD. Inyectar AdamW sin recalibrar la tasa de aprendizaje provocó colapso de gradientes (mAP: 18.34%).
- **Dominio geométrico (V1):** Sin mosaico, el modelo obtuvo el **Box Loss más bajo** (0.0728), demostrando que conservar la estructura original del coche favorece la localización espacial.

Métricas



El Desafío del Overfitting Estadístico

La sospecha

Un mAP50-95 del **98.70%** levantó sospechas de sobreajuste extremo.

Diagnóstico: Fuga de Datos

Los fotogramas extraídos de secuencias de vídeo, separados por escasos milisegundos, presentaban al mismo conductor y habitáculo tanto en entrenamiento como en evaluación.

Consecuencia

Las métricas del examen final estaban artificialmente infladas. El modelo no demostraba generalización, sino reconocimiento de condiciones exactas de iluminación, fondos y sujetos del dataset.

Validación Empírica y Domain Shift

Se construyó un prototipo funcional con **Streamlit** para probar el modelo en escenarios reales ajenos al entrenamiento (Out-of-Distribution).

Escenario A — Imágenes similares

Con focal, perspectiva e iluminación afines, el modelo **mantuvo precisión notable**: aisló correctamente móvil, brazos y postura. Demuestra sólida generalización conceptual.

Escenario B — Webcam en vivo

Con ángulos frontales, distinta temperatura de color y posturas no estandarizadas, el rendimiento **cayó drásticamente**.

Diagnóstico: Domain Shift

La red neuronal generó fuerte dependencia a la "**firma óptica**" de la cámara del dataset original. El modelo sabe qué buscar, pero solo lo encuentra si la imagen se ajusta a las reglas memorizadas.

App Streamlit

- Carga de imágenes para probar el modelo con distintos escenarios de entrada.
- Procesamiento en tiempo real para evaluar el comportamiento del conductor de forma inmediata.
- Visualización de detecciones mediante bounding boxes sobre las regiones de interés.



Conclusiones Clave y Próximos Pasos

1 Validación Empírica Esencial

Las métricas de laboratorio pueden ser engañosas. Es vital validar el rendimiento del modelo en escenarios reales y no vistos para comprender su verdadera capacidad de generalización.

2 Mitigar el Domain Shift

El rendimiento del modelo cayó drásticamente en entornos Out-of-Distribution. Futuros trabajos deben centrarse en técnicas como la adaptación de dominio o el aumento de datos inteligente para robustecer la detección.

3 Optimización Continua

Aunque YOLOv8 Nano demostró ser un modelo ligero y eficaz, la exploración de diferentes configuraciones de entrenamiento y arquitecturas sigue siendo fundamental para maximizar su eficiencia y precisión en condiciones variadas.

4 Hacia la Implementación Real

El prototipo de Streamlit confirma la viabilidad del concepto. Los próximos pasos incluyen la integración con hardware embebido y la realización de pruebas piloto en vehículos para recopilar datos reales y cerrar el ciclo de mejora.

Gracias por su atención

Carlos Seoane, Miguel Valle, Santiago Nuñez